Pamukkale Üniversitesi

İktisadi ve İdari Bilimler Fakültesi

Yönetim Bilişim Sistemleri

Öğrencilerde Depresyon Riskinin Lojistik Regresyon ile Modellenmesi

YBS 441 – Veri Madenciliği Teknikleri

Ders Dönemi: 2025-2026 Güz

Sorumlu Öğretim Elemanı: **Prof. Dr. Selçuk Burak HAŞILOĞLU**

Ders Asistanı: **Arş. Gör. Berker DAL**

Selin Pir

22219035

İçindekiler

Giriş 3

1-İşin Anlaşılması 3

2-Verinin Anlaşılması 4

3-Verinin Hazırlanması 6

4-Modelleme 7

5-Değerlendirme 8

Ekler 11

Ek–A: Kullanılan Python Kodları 11

Ek–B: Ek Tablolar ve Şekiller 11

Ek–C: Orijinal Veri Seti 16

Giriş

Üniversite öğrencileri, akademik baskı, gelecek kaygısı, finansal zorluklar ve sosyal ilişkilerdeki değişimler nedeniyle ruh sağlığı açısından riskli bir grubu oluşturmaktadır. Bu dönemde yaşanan depresif belirtiler; akademik başarıda düşüş, okul terki, sosyal izolasyon ve intihar girişimi gibi ciddi sonuçlara yol açabilmektedir. Bu nedenle, öğrencilerde depresyon riskinin erken dönemde tespit edilmesi ve riskli bireylerin uygun destek mekanizmalarına yönlendirilmesi hem bireysel açıdan hem de eğitim kurumlarının sürdürülebilirliği açısından kritik önem taşımaktadır.

Geleneksel yaklaşımda depresyon, çoğunlukla bireyin kendi başvurusu, klinik değerlendirme veya ölçek temelli tarama sonuçları üzerinden ele alınmaktadır. Ancak bu yöntemler hem zaman ve uzmanlık gerektirmesi hem de çoğu öğrencinin yardım arama davranışı göstermemesi nedeniyle tüm riskli grubun yakalanmasında yetersiz kalabilmektedir. Bu noktada veri madenciliği ve makine öğrenmesi yöntemleri, mevcut verilerden yararlanarak depresyon ile ilişkili örüntüleri ortaya çıkarma ve riskli öğrencileri otomatik olarak işaretleme potansiyeli sunmaktadır.

Bu çalışma kapsamında, Kaggle üzerinde yayımlanan "Student Depression Dataset" veri seti kullanılarak öğrencilerin depresyonda olup olmadığını tahmin etmeye yönelik bir sınıflandırma modeli geliştirilmiştir. Veri setinde yer alan demografik (cinsiyet, yaş, şehir, meslek), akademik (not ortalaması, akademik baskı, ders memnuniyeti, eğitim durumu), iş/finansal (iş baskısı, iş memnuniyeti, finansal stres, günlük çalışma saatleri) ve psikososyal/yaşam tarzı değişkenleri (uyku süresi, beslenme alışkanlıkları, intihar düşünceleri, ailede ruh sağlığı öyküsü) kullanılarak, depresyon durumunu ikili (0 = yok, 1 = var) olarak modelleyen bir lojistik regresyon modeli kurulmuştur.

Çalışmanın temel amacı, öğrencilerin depresyon durumunu kabul edilebilir doğrulukta tahmin edebilen bir model geliştirmekle birlikte, sadece tahmin performansını değil, aynı zamanda depresyon riskini artıran ve azaltan faktörleri de ortaya koymaktır. Bu doğrultuda CRISP-DM (Cross-Industry Standard Process for Data Mining) metodolojisi izlenmiş; sırasıyla iş anlayışı, veri anlayışı, veri hazırlama, modelleme, değerlendirme ve sonuçların yorumlanması adımları gerçekleştirilmiştir. Böylece hem teknik açıdan geçerli hem de eğitim kurumlarının karar verme süreçlerine girdi sağlayabilecek nitelikte bir çalışma ortaya koyulması hedeflenmiştir.

1-İşin Anlaşılması

Bu projenin çıkış noktası, üniversite öğrencilerinin ruh sağlığıyla ilgili çok sık konuşulan ama çoğu zaman sistemli bir şekilde takip edilemeyen bir soruya odaklanmaktadır: "Elimizdeki verilerden yola çıkarak, hangi öğrencilerin depresyonda olma ihtimali daha yüksektir?" Çalışmanın temel problemi, öğrencilere ait çeşitli özellikleri (yaş, cinsiyet, not ortalaması, akademik baskı, finansal stres, uyku süresi, intihar düşünceleri vb.) kullanarak, öğrencinin depresyonda olup olmadığını 0-1 şeklinde tahmin eden bir model kurmaktır.

Buradaki amaç, tıbbi tanı koymak ya da psikologların yerini almak değildir. Modelden beklenen, daha çok bir erken uyarı sistemi gibi davranmasıdır. Örneğin bir üniversite düşünelim: Binlerce öğrencisi var ve hepsiyle tek tek detaylı görüşme yapmak mümkün değil. Eğer öğrencilerin bazı temel bilgileri ve anket cevapları kullanılarak "riskli olabilir" görünen bir grup önceden belirlenebilirse, rehberlik ve

psikolojik danışmanlık birimleri görüşmelerini bu grubu önceliklendirecek şekilde planlayabilir. Bu açıdan bakıldığında, model bir karar verici değil; riskli öğrencileri işaretleyen yardımcı bir araç olarak tasarlanmaktadır.

Bu bağlamda projenin iş hedefi şöyle özetlenebilir:

- Öğrencilerin demografik, akademik, finansal ve psikososyal özelliklerinden yola çıkarak depresyon riskini tahmin etmek,
- Bu tahminleri kullanarak, hangi faktörlerin depresyonla daha yakından ilişkili olduğunu görmek,
- Elde edilen sonuçların ileride yapılabilecek olası müdahale ve destek programları için fikir vermesini sağlamak.

Depresyon taraması açısından bakıldığında, asıl kritik olan, depresyonu olduğu hâlde "yok" denilen öğrencilerin sayısını olabildiğince azaltmaktır. Bu yüzden, model değerlendirilirken depresyon sınıfına ait recall metriği öncelikli olarak ele alınmış, yanlış negatiflerin mümkün olduğunca düşük olması hedeflenmiştir.

Sonuç olarak, iş anlayışı adımında bu proje; bir üniversite ortamında toplanabilecek öğrenci verilerini kullanarak, depresyon riski hakkında öngörü üreten, riskli grupları daha erken fark etmeye yardımcı olabilecek ve aynı zamanda hangi faktörlerin bu riski artırıp azalttığına dair fikir veren bir veri madenciliği uygulaması olarak tanımlanmıştır. Bu çerçeve, sonraki bölümlerde yapılacak olan veri analizi, modelleme ve sonuçların yorumlanması adımlarına temel oluşturmaktadır.

2-Verinin Anlaşılması

Veri seti, üniversite çağındaki bireylerden toplanan ve öğrencilerin ruh sağlığına etki edebileceği düşünülen çeşitli özellikleri içermektedir. Ham veriyi projeye aktardıktan sonra, ilk olarak değişken isimlerinin ve içeriklerinin anlaşılır hâle getirilmesi hedeflenmiştir. Bu amaçla, değişken isimleri hem Türkçeleştirilmiş hem de modelleme sürecinde daha rahat kullanılabilecek biçimde yeniden adlandırılmıştır. Örneğin "Gender" sütunu "cinsiyet", "Age" sütunu "yas", "City" sütunu "sehir", "Profession" sütunu "meslek", "Academic Pressure" sütunu "akademik_baski", "Work Pressure" sütunu "is_baskisi", "CGPA" sütunu "not_ortalamasi_cgpa", "Sleep Duration" sütunu "uyku_suresi", "Dietary Habits" sütunu "beslenme_aliskanliklari", "Have you ever had suicidal thoughts?" sütunu "intihar_dusunceleri", "Family History of Mental Illness" sütunu "ailede_ruh_sagligi_oykusu" ve "Depression" sütunu "depresyon" adıyla düzenlenmiştir. Böylece hem analiz hem de raporlama sürecinde Türkçe ve anlaşılır terimlerle ilerlemek mümkün olmuştur.

Veri setinde yer alan değişkenler genel olarak üç ana kategori altında toparlanabilir. Birincisi, demografik değişkenlerdir: cinsiyet, yas, sehir ve meslek. Bu değişkenler, öğrencilerin temel sosyo-demografik profillerini yansıtmakta ve farklı gruplar arasında depresyon riskinin değişip değişmediğini incelemek için kullanılmaktadır. İkincisi, akademik ve iş yüküyle ilişkili değişkenlerdir: akademik_baski, not_ortalamasi_cgpa, ders_memnuniyeti, is_baskisi, is_memnuniyeti, gunluk_calisma_saatleri ve egitim_durumu. Bu grup, öğrencilerin eğitim hayatına ve varsa çalışma yaşamına ilişkin algılarını ve yükünü yansıtmakta; akademik/mesleki stresin depresyon üzerindeki etkisinin araştırılmasına imkân vermektedir. Üçüncüsü ise psikososyal ve yaşam tarzı değişkenleridir:

uyku_suresi, beslenme_aliskanliklari, finansal_stres, intihar_dusunceleri ve ailede_ruh_sagligi_oykusu. Bu değişkenler, öğrencilerin günlük yaşam alışkanlıklarını, finansal durum algılarını ve ruh sağlığı açısından bilinen risk faktörlerini (örneğin intihar düşüncesi, ailede ruhsal hastalık öyküsü) temsil etmektedir.

Veri anlayışı aşamasında ilk incelenen noktalardan biri, hedef değişken olan "depresyon" sütununun sınıf dağılımı olmuştur. Depresyon değişkeni ikili (binary) yapıdadır: 0 değeri "depresyon yok", 1 değeri ise "depresyon var" anlamına gelmektedir. Sınıf dağılımı incelendiğinde, depresyon var (1) sınıfının depresyon yok (0) sınıfına göre daha fazla gözlem içerdiği, ancak aşırı bir dengesizlik bulunmadığı görülmüştür. Yani veri seti, tamamen dengeli olmasa da tek taraflı olarak yalnızca bir sınıfın baskın olduğu bir yapı da göstermemektedir.

Veriyi daha iyi tanıyabilmek için hem sayısal hem kategorik değişkenler için temel betimleyici istatistikler ve görsel özetler oluşturulmuştur. Sayısal değişkenler (yas, not_ortalamasi_cgpa, akademik_baski, is_baskisi, ders_memnuniyeti, is_memnuniyeti, gunluk_calisma_saatleri, finansal_stres gibi) için minimum, maksimum, ortalama, medyan ve çeyrek değerler incelenmiş; böylece verinin genel düzeyi ve olası uç değerler hakkında ilk fikir elde edilmiştir. Örneğin yaş değişkeninin çoğunlukla genç yetişkin aralıklarında yoğunlaştığı, not ortalamalarının 0-10 aralığında makul bir dağılım sergilediği görülmüştür. Akademik_baski, ders_memnuniyeti ve finansal_stres gibi ölçek tipi değişkenler için ise değerlerin çoğunlukla orta düzeylerde yığıldığı, ancak bazı öğrencilerin uç değerler bildirdiği gözlemlenmiştir.

Kategorik değişkenler için frekans tabloları ve çubuk grafikleri kullanılmıştır. Örneğin cinsiyet dağılımına bakılarak veri setinde kadın ve erkek öğrencilerin yaklaşık oranları incelenmiş; uyku_suresi değişkeni için "5 saatten az", "5-6 saat", "7-8 saat" ve "8 saatten fazla" gibi kategorilerin hangi aralıkta yoğunlaştığı gözlemlenmiştir. Benzer şekilde, beslenme_aliskanliklari sütununda "Sağlıksız", "Orta" ve "Sağlıklı" gruplarının oranları; intihar_dusunceleri ve ailede_ruh_sagligi_oykusu sütunlarında "Evet/Hayır" yanıtlarının dağılımı incelenmiştir. Bu grafikler, modelleme aşamasına geçmeden önce veri setindeki örüntüler hakkında görsel bir sezgi kazanılmasını sağlamış, örneğin intihar düşüncesi bildiren öğrencilerin sayısının azımsanmayacak bir düzeyde olduğunu ve bu grubun depresyon sınıfı ile yakından ilişkili olabileceğini düşündürmüştür. Bu grafikler raporun ekler bölümünde sunulmuştur (bkz. Ek–B: Ek Tablolar ve Şekiller).

Yaş ve not_ortalamasi_cgpa gibi bazı sayısal değişkenler için daha detaylı uç değer (outlier) incelemesi yapılmıştır. Verinin anlaşılması aşamasında bu değerler öncelikle görsel olarak tespit edilmiş, daha sonra veri hazırlama bölümünde interquartile range (IQR) yöntemi ve alan bilgisi kullanılarak hangi gözlemlerin gerçekten sorunlu sayılacağına karar verilmiştir. Örneğin, yaş değişkeninde 15 yaşın altındaki veya 40 yaşın üzerindeki gözlemlerin çok az sayıda olduğu görülmüş ve bu değerlerin öğrenci profilini ne kadar temsil ettiği ayrıca tartışılmıştır.

Sonuç olarak, verinin anlaşılması adımı; veri setinin yapısını, değişken türlerini, temel dağılımları ve değişkenler arası ilişkileri ortaya koyarak, ilerleyen aşamalarda yapılacak veri temizleme, dönüştürme ve model kurma kararları için bir temel oluşturmuştur. Bu aşamada elde edilen bulgular, hangi değişkenlerin doğrudan modele gireceği, hangilerinin dönüştürülmesi gerektiği ve hangi alanlarda daha dikkatli olunması (örneğin sınıf dengesizliği, uç değerler, eksik değerler) gerektiği konusunda yol gösterici olmuştur.

3-Verinin Hazırlanması

Veri hazırlama aşamasında temel amaç, ham veri setini hem keşifsel analizler hem de makine öğrenmesi modeli için uygun, tutarlı ve yorumlanabilir bir yapıya dönüştürmektir. Bu kapsamda sütun adlarının düzenlenmesi, veri tiplerinin düzeltilmesi, aykırı değerlerin incelenmesi, eksik değerlerin ele alınması, kategorik değişkenlerin sayısal forma dönüştürülmesi ve son olarak değişkenlerin ölçeklenmesi adımları uygulanmıştır.

Modelleme aşamasında bağımlı değişken olarak "depresyon" sütunu belirlenmiştir. "id" sütunu ise öğrencileri sadece tanımlamaya yarayan bir kimlik bilgisi olduğu ve herhangi bir tahmin gücü taşımadığı için modelleme sürecine dahil edilmemiştir. Bu nedenle özellik matrisi X, "id" ve "depresyon" sütunları çıkarıldıktan sonra kalan tüm değişkenlerden oluşturulmuş, hedef değişken y ise "depresyon" sütununun kendisi olarak tanımlanmıştır. Bu ayrım, CRISP-DM sürecindeki veri hazırlama ile modelleme adımlarını net şekilde birbirinden ayırmak açısından da önemlidir.

Tip dönüşümleri ve sayısal formata geçiş

Veri seti incelendiğinde, gerçekte sayısal bilgi taşıyan bazı sütunların dosyanın yapısı nedeniyle "object" (metin) türünde kayıtlı olduğu görülmüştür. Bu durum makine öğrenmesi algoritmalarının bu değişkenleri doğrudan kullanmasını güçleştirmektedir. Bu nedenle veri hazırlama sürecinin erken bir aşamasında, sayısal içeriğe sahip olduğu hâlde metin formatında tutulan değişkenler uygun dönüştürme işlemleriyle float veya int tipine çevrilmiştir. Örneğin not_ortalamasi_cgpa, akademik_baski, finansal_stres ve gunluk_calisma_saatleri gibi sütunlar sayısal formata dönüştürülmüş, böylece bu değişkenler üzerinde istatistiksel işlem yapmak ve modeli beslemek mümkün hâle gelmiştir.

Tip dönüşümleri yalnızca klasik sayısal değişkenlerle sınırlı tutulmamış, aynı zamanda bazı kategorik değişkenler de modelin daha verimli ve anlamlı bir şekilde kullanabileceği sayısal temsillere dönüştürülmüştür. Özellikle sıralı (ordinal) yapıda olduğu kabul edilen değişkenler için bu dönüşüm önem taşımaktadır. Örneğin beslenme_aliskanliklari değişkeni, "Sağlıksız", "Orta" ve "Sağlıklı" biçimindeki kategorilerden oluşmaktadır. Bu değişken, beslenme kalitesinin derecesini yansıtacak şekilde 0, 1 ve 2 değerleri ile kodlanarak beslenme_kod isimli sayısal bir sütuna dönüştürülmüştür.

Aykırı değer analizi ve alınan kararlar

Veri hazırlama sürecinde, modelin güvenilirliğini olumsuz etkileyebilecek aşırı uç gözlemleri belirlemek amacıyla aykırı değer analizi yapılmıştır. Her bir değişken için birinci çeyrek (Q1), üçüncü çeyrek (Q3) ve bunların farkı olan IQR hesaplanmış, ardından alt sınır Q1 – 1.5×IQR, üst sınır ise Q3 + 1.5×IQR olarak belirlenmiştir. Bu sınırların dışında kalan gözlemler potansiyel aykırı değerler olarak işaretlenmiş ve sayıları raporlanmıştır.

Yaş değişkeni için yapılan analiz, veri setinde çok düşük veya çok yüksek yaş değerlerinin çok az sayıda bulunduğunu göstermiştir. Veri setinin üniversite öğrencilerini temsil ettiği dikkate alınarak, yaş için makul aralık 15-40 olarak belirlenmiş ve bu aralığın dışında kalan gözlemler veri setinden çıkarılmıştır. Böylece hem veri giriş hatası olma ihtimali yüksek gözlemler elimine edilmiş hem de modelin gerçekçi bir öğrenci profili üzerinde eğitilmesi sağlanmıştır. Diğer sayısal değişkenler için de benzer IQR analizleri yapılmış, ancak tespit edilen az sayıda aykırı gözlemin model performansını bozacak düzeyde olmadığı görülmüştür. Bu nedenle, yalnızca yaş değişkeninde filtreleme uygulanmış,

diğer değişkenlerde gözlemler korunmuştur. Bu yaklaşım, veri setinin yapısını gereksiz yere bozmadan, makul bir temizleme düzeyine ulaşmayı amaçlayan dengeli bir tercih olarak değerlendirilebilir.

Eksik değerlerin ele alınması

Eksik değerler, veri madenciliği projelerinde modelin doğruluğunu ve genellenebilirliğini olumsuz etkileyebilen önemli bir konudur. Bu nedenle veri seti eksik değerler açısından ayrıntılı şekilde incelenmiştir. Başlangıçta, ham veri üzerinde yapılan kontroller, çoğu değişkende eksik değer bulunmadığını göstermiştir. Ancak veri tiplerini sayısal formata dönüştürürken sınırlı sayıda eksik değer ortaya çıkmıştır. Özellikle finansal_stres sütununda, bu dönüşüm sonrasında üç gözlem eksik değer olarak işaretlenmiştir.

Eksik değerlerin doğrudan silinmesi, veri setinde gereksiz gözlem kaybına yol açacağından, bu çalışmada eksik değerler için imputasyon uygulanması tercih edilmiştir. Finansal_stres sütunundaki üç eksik gözlem, bu sütunun medyan değeri ile doldurulmuştur. Medyan, özellikle uç değerlerden daha az etkilenen bir ortalama ölçüsü olduğu için, bu seçim hem sütunun genel dağılımını korumakta hem de modelin dengesini bozmamaktadır.

Kategorik değişkenlerin kodlanması

Lojistik regresyon modeli tamamen sayısal girdilerle çalıştığı için, veri setindeki tüm kategorik değişkenlerin sayısal forma dönüştürülmesi gerekmiştir. Bu amaçla, değişkenlerin yapısına göre iki farklı kodlama yaklaşımı kullanılmıştır. İkili yapıda olan değişkenler için basit 0/1 kodlama tercih edilmiştir. Bu sayede bu değişkenler doğrudan lojistik regresyon modeline girdi olarak verilebilmiştir.

Birden fazla kategori içeren değişkenler için ise one-hot encoding (dummy değişkenler) kullanılmıştır. Şehir, meslek ve egitim_durumu gibi çok kategorili değişkenler, her kategori için ayrı bir sütun oluşturulacak şekilde genişletilmiş; ilgili kategorideki gözlemler için bu sütunlar 1, diğerleri için 0 değerini almıştır. Örneğin sehir değişkeni, “sehir_Delhi”, “sehir_Mumbai”, “sehir_Hyderabad” gibi birden fazla dummy sütunla temsil edilmiştir. Çoklu doğrusal bağlantı riskini azaltmak ve gereksiz fazlalığı önlemek amacıyla, bazı durumlarda bir referans kategori dışarıda bırakılmıştır. Bu kodlama işlemleri sonucunda, veri setinde kategorik bilgiler one-hot ve 0/1 kodlama ile temsil edilmekte ve yaklaşık 100’ün üzerinde özelliğe sahip, tamamen sayısal bir X matrisi elde edilmektedir.

4-Modelleme

Veri hazırlama adımlarının tamamlanmasının ardından, CRISP-DM sürecinin modelleme aşamasında öğrencilerin depresyonda olup olmadığını tahmin edebilecek bir sınıflandırma modeli kurulmuştur. Bu çalışmada hedef değişken ikili yapıdadır (0 = depresyon yok, 1 = depresyon var) ve veri seti, ağırlıklı olarak demografik, akademik ve psikososyal değişkenlerden oluşan bir özellik kümesi sunmaktadır. Bu nedenle, denetimli öğrenme kapsamında ikili sınıflandırma yapabilen algoritmalar değerlendirilmiş hem yorumlanabilirlik hem de temel performans açısından uygun bir başlangıç noktası sunması sebebiyle lojistik regresyon tercih edilmiştir.

Model kurulumuna geçmeden önce, hazırlanan veri seti eğitim ve test kümelerine ayrılmıştır. Çalışmada, veri seti belirli bir oranda eğitim ve test setlerine bölünmüştür. Eğitim ve test kümeleri oluşturulduktan sonra, sayısal değişkenler üzerinde standardizasyon uygulanmıştır. Veri setinde yer

alan yaş, akademik_baski, not_ortalamasi_cgpa, finansal_stres, gunluk_calisma_saatleri gibi değişkenler farklı ölçeklerde değerler almaktadır. Örneğin yaş değişkeni iki haneli değerlerden oluşurken, bazı ölçek değişkenleri 1-5 aralığında, not ortalaması 0-10 aralığında değişmektedir. Eğitim verisi üzerinde standartlaştırma yapılarak her bir sayısal özelliğin ortalaması sıfır, standart sapması bir olacak şekilde dönüştürülmüştür. Standardizasyon parametreleri (ortalama ve standart sapma) yalnızca eğitim seti kullanılarak hesaplanmış, veri sızıntısını engellemek için test setine bu parametreler doğrudan uygulanmış; test verisi üzerinde herhangi bir yeniden "fit" işlemi yapılmamıştır. Böylece hem modelin gelecekte göreceği yeni verilerle nasıl çalışacağına dair daha gerçekçi bir senaryo elde edilmiş, hem de eğitim-test ayrımının istatistiksel anlamı korunmuştur.

Model olarak kullanılan lojistik regresyon, Python ortamında scikit-learn kütüphanesi aracılığıyla uygulanmıştır. Lojistik regresyon modeli, bağımlı değişken olarak depresyon durumunu, bağımsız değişkenler olarak ise daha önce sayısallaştırılmış ve gerekli dönüşümlerden geçirilmiş tüm özellikleri (yaş, not ortalaması, akademik ve finansal baskı, uyku süresi, beslenme düzeyi, intihar düşüncesi, ailede ruh sağlığı öyküsü, şehir, meslek, eğitim durumu vb.) girdi olarak almıştır. Model, eğitim setinin ölçeklenmiş versiyonu üzerinde eğitilmiş; çözümde kullanılacak optimizasyon algoritması veri boyutu ve ikili sınıflandırma yapısı göz önünde bulundurularak seçilmiştir. Eğitim işlemi tamamlandıktan sonra, eğitilmiş lojistik regresyon modeli kullanılarak test setindeki gözlemler için depresyon tahminleri üretilmiştir.

Modelleme aşamasında ayrıca, ilerleyen değerlendirme adımları için hangi başarı ölçütlerinin kullanılacağı da önceden belirlenmiştir. Bu kapsamda, modelin genel performansını görmek için doğruluk oranı (accuracy), sınıf bazlı davranışını incelemek için hassasiyet (precision), duyarlılık (recall) ve F1 skoru; hata türlerinin dağılımını görmek için de karmaşıklık matrisi (confusion matrix) hesaplanmasına karar verilmiştir. Lojistik regresyonun olasılık tahmini üretebilme özelliği sayesinde, modelin kesme noktasına bağlı performansını inceleyebilmek amacıyla ROC eğrisi ve AUC (Area Under the Curve) değeri de değerlendirme kapsamında düşünülmüştür.

Bu çerçevede, modelleme aşaması; standartlaştırılmış özellikler üzerinde eğitilen ve ikili depresyon sınıflandırmasını gerçekleştiren bir lojistik regresyon modeliyle tamamlanmış, elde edilen modelin hem tahmin gücünü hem de yorumlanabilirliğini değerlendirmek üzere bir sonraki aşama olan değerlendirme adımına geçilmiştir.

5-Değerlendirme

Modelleme aşamasında kurulan lojistik regresyon modelinin başarımı, test veri seti üzerinde çeşitli sınıflandırma metrikleri kullanılarak değerlendirilmiştir. Elde edilen test doğruluk oranı yaklaşık %84,65'tir (Accuracy = 0.8465). Bu değer, modelin test kümesindeki 5577 öğrencinin önemli bir kısmını doğru sınıflandırabildiğini göstermektedir. Test setinde depresyonda olan öğrenciler (sınıf 1) 3266 kişi, depresyonda olmayanlar (sınıf 0) ise 2311 kişidir. Bu çalışmanın bağlamında asıl kritik nokta, depresyonda olan öğrencilerin (sınıf 1) olabildiğince az kaçırılmasıdır. Bu nedenle sınıflandırma raporundaki precision, recall ve F1 skorları ayrıca incelenmiştir. Depresyonu olmayan öğrenciler için (sınıf 0) hassasiyet 0.83, duyarlılık 0.79 ve F1 skoru 0.81; depresyonda olan öğrenciler için (sınıf 1) ise hassasiyet 0.86, duyarlılık 0.89 ve F1 skoru 0.87 olarak elde edilmiştir. Bu sonuçlar, modelin her iki sınıfı da makul bir başarıyla ayırt edebildiğini, ancak özellikle depresyon sınıfı için daha güçlü bir

performans sergilediğini göstermektedir. Sınıf 1 için 0.89'luk recall değeri, test setinde depresyonda olan öğrencilerin yaklaşık %89'unun model tarafından doğru şekilde "depresyon var" olarak işaretlendiği anlamına gelmektedir. Rehberlik ve psikolojik destek süreçleri açısından bakıldığında, riskli bireyleri mümkün olduğunca az kaçırmak kritik olduğundan, bu değer iş hedefiyle oldukça uyumludur.

Modelin hangi tür hataları hangi sıklıkta yaptığını görmek için karmaşıklık matrisi incelenmiştir. Test setine ilişkin karmaşıklık matrisi, gerçek değeri 0 olan 2311 öğrenciden 1826'sının doğru şekilde "depresyon yok" olarak sınıflandırıldığını, 485'inin ise hatalı şekilde "depresyon var" olarak işaretlendiğini göstermektedir. Gerçek değeri 1 olan 3266 öğrenciden 2895'i doğru şekilde "depresyon var" olarak tahmin edilmiş, 371'i ise yanlış negatif olarak "depresyon yok" şeklinde sınıflandırılmıştır. Model depresyonda olan öğrencileri yakalama konusunda güçlü, ancak bu başarıyı sağlarken bir miktar yanlış alarm üretmeyi göze almaktadır. Yanlış pozitifler (depresyonu olmadığı hâlde riskli görülen öğrenciler) rehberlik sistemi içinde yapılacak ek görüşme ve değerlendirmelerle elenebilirken, yanlış negatifler sistemde hiç görünmeden gözden kaçabilir. Bu nedenle, yanlış negatif sayısının görece düşük olması ve depresyon sınıfı için yüksek recall elde edilmesi, çalışmanın başlangıçta belirlenen iş hedefleri açısından olumlu bir sonuçtur.

Modelin ayrıştırma gücünü, sınıflandırma eşiğine bağlı olmadan değerlendirebilmek için ROC-AUC metriği de hesaplanmıştır. Elde edilen ROC-AUC skoru 0.9185 olup, bu değer modelin depresyonda olan ve olmayan öğrencileri olasılık düzeyinde oldukça iyi ayırt edebildiğini göstermektedir. AUC'nin 0.5'e yakın olduğu durumlar tesadüfi tahmine, 1.0'a yaklaştığı durumlar ise çok güçlü ayrıştırma performansına işaret etmektedir.

Modelin sayısal performansının ötesinde, hangi değişkenlerin depresyon olasılığı üzerinde nasıl bir etkiye sahip olduğunun anlaşılması da önemlidir. Bu amaçla lojistik regresyonun katsayıları ve bunların üstel karşılıkları olan odds ratio değerleri incelenmiştir. Pozitif katsayıya ve 1'in üzerinde odds ratio'ya sahip değişkenler diğer koşullar sabitken depresyonda olma olasılığını artırma eğilimindeyken, negatif katsayıya ve 1'in altında odds ratio'ya sahip değişkenler depresyon riskini azaltma eğilimindedir. En yüksek pozitif etkiye sahip değişkenlerden birinin intihar_dusunceleri_kod olduğu görülmüştür; bu değişkenin katsayısı yaklaşık 1.22, odds ratio değeri ise 3.38'dir. Bu sonuç, diğer tüm değişkenler sabitken, intihar düşüncesi bildiren öğrencilerin depresyonda olma odds'unun, intihar düşüncesi bildirmeyenlere göre yaklaşık 3.4 kat daha yüksek olduğunu göstermektedir. Bu, literatürle de uyumlu şekilde intihar düşüncesinin ciddi bir risk göstergesi olduğunu desteklemektedir.

Benzer şekilde, akademik_baski için elde edilen katsayı 1.16, odds ratio değeri ise yaklaşık 3.20'dir. Akademik baskı düzeyindeki her bir birim artış, depresyon odds'unu yaklaşık 3.2 katına çıkarmaktadır. Bu bulgu, yüksek akademik baskı altında olan öğrencilerin ciddi bir risk grubu olduğunu göstermekte ve eğitim kurumlarının akademik beklenti düzeyi, sınav baskısı ve performans kaygısı gibi unsurlara dikkat etmesi gerektiğine işaret etmektedir. finansal_stres değişkeni de önemli bir risk faktörü olarak ortaya çıkmıştır; odds ratio değeri yaklaşık 2.25'tir. Bu, finansal stres puanındaki artışların depresyon olasılığını anlamlı biçimde yükselttiğini, ekonomik kaygıların öğrencilerin ruh sağlığı üzerinde belirgin bir etkisi olduğunu göstermektedir. gunluk_calisma_saatleri için elde edilen yaklaşık 1.53'lük odds ratio değeri, günlük çalışma/çalışma-öğrenim süresi arttıkça depresyon riskinin de artma eğiliminde olduğunu ortaya koymaktadır. Ayrıca ailede_ruh_sagligi_oykusu_kod için bulunan

yaklaşık 1.14'lük odds ratio, ailede ruh sağlığı problemi öyküsü olmasının risk artırıcı bir faktör olduğunu göstermektedir.

Negatif katsayıya sahip değişkenler incelendiğinde, bazı değişkenlerin depresyonla ters yönlü ilişkileri dikkat çekmiştir. yas değişkeni için elde edilen katsayı -0.576 ve odds ratio 0.56'dır; bu, yaş arttıkça (örneğin genç lisans öğrencilerinden nispeten daha büyük yaş grubuna geçtikçe) depresyon olasılığının azalma eğiliminde olabileceğini göstermektedir. Bu bulgu, örneklem yapısı ve veri setinin sınırları içinde yorumlanmalıdır; daha büyük yaş gruplarının hayata ve eğitime uyum konusunda farklı bir denge yakalamış olma ihtimali bulunmaktadır. beslenme_kod için bulunan -0.438'lik katsayı ve 0.65'lik odds ratio, daha sağlıklı beslenme alışkanlıklarına sahip öğrencilerin depresyonda olma olasılığının daha düşük olduğunu göstermektedir. Benzer şekilde ders_memnuniyeti için bulunan -0.324'lük katsayı (odds ratio ≈ 0.72), öğrencilerin derslerinden memnuniyet düzeyi arttıkça depresyon riskinin azaldığına işaret etmektedir. uyku_suresi_saat değişkeni için elde edilen yaklaşık 0.81'lik odds ratio da daha uzun uyku sürelerinin depresyon olasılığını azaltma eğiliminde olduğunu ortaya koymaktadır. Bu sonuçlar bir arada değerlendirildiğinde, yeterli uyku, daha sağlıklı beslenme ve yüksek ders memnuniyeti gibi faktörlerin koruyucu bir rol oynayabileceği; buna karşılık yoğun akademik ve finansal baskı, fazla çalışma süresi ve intihar düşüncesi gibi faktörlerin risk faktörü olduğu söylenebilir.

CRISP-DM çerçevesi açısından bakıldığında, değerlendirme aşaması yalnızca metriklerin raporlanmasını değil, aynı zamanda bu sonuçların iş hedefleriyle ne kadar uyumlu olduğunun sorgulanmasını da içermelidir. Bu çalışmada iş hedefi, depresyon riski taşıyan öğrencileri erken aşamada tespit ederek rehberlik ve psikolojik destek süreçlerine yönlendirmeye yardımcı olabilecek bir model geliştirmek olarak tanımlanmıştır. Elde edilen sonuçlar, bu hedefle büyük ölçüde uyumlu görünmektedir: model, basit bir çoğunluk sınıfı tahminine göre belirgin derecede daha yüksek doğruluk sağlamış; özellikle depresyon sınıfı için yüksek duyarlılık ve anlamlı bir ROC-AUC değeri üreterek riskli öğrencilerin büyük kısmını işaretleyebilmiştir. Bununla birlikte, yanlış negatiflerin tamamen ortadan kalkmadığı, yanlış pozitiflerin ise rehberlik kaynakları üzerinde ek yük oluşturabileceği unutulmamalıdır. Bu nedenle, model çıktılarının nihai bir tanı aracı olarak değil, rehberlik ve danışmanlık sistemleri için ön tarama ve önceliklendirme desteği sağlayan bir karar destek aracı olarak kullanılması daha uygun olacaktır.

Tüm bu değerlendirmenin sonucunda, kurulan lojistik regresyon modeli, öğrencilerde depresyon riskini tahmin etmek için CRISP-DM sürecine uygun, performansı tatmin edici ve yorumlanabilir bir başlangıç çözümü sunmaktadır. Gelecek çalışmalarda farklı algoritmaların denenmesi, farklı veri setlerinde dış doğrulama yapılması ve karar eşiğinin senaryolara göre ayarlanması gibi adımlarla modelin güçlendirilmesi mümkündür. Ancak bu proje kapsamında elde edilen sonuçlar, belirlenen iş hedefleri doğrultusunda modelin amacına büyük ölçüde hizmet ettiğini göstermektedir.

Ekler

Ek–A: Kullanılan Python Kodları

https://github.com/selinpir/my-datascience-path/tree/main/ogrenci_depresyon_lojistik_regresyon-kaggle

Şekil 1:Kodların Tamamı

Ek–B: Ek Tablolar ve Şekiller

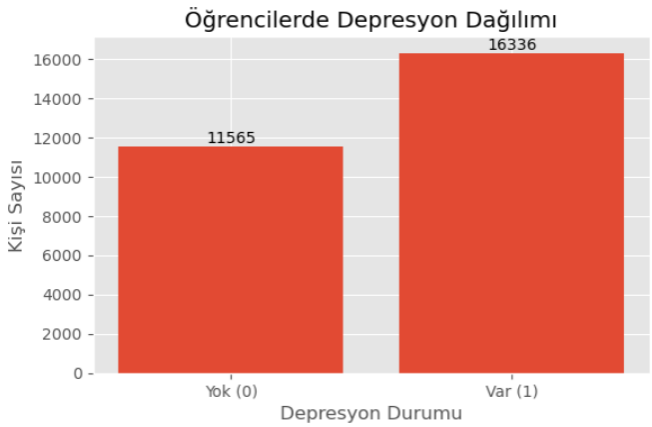

Şekil 2: Öğrencilerin Depresyon Dağılımı (EDA)

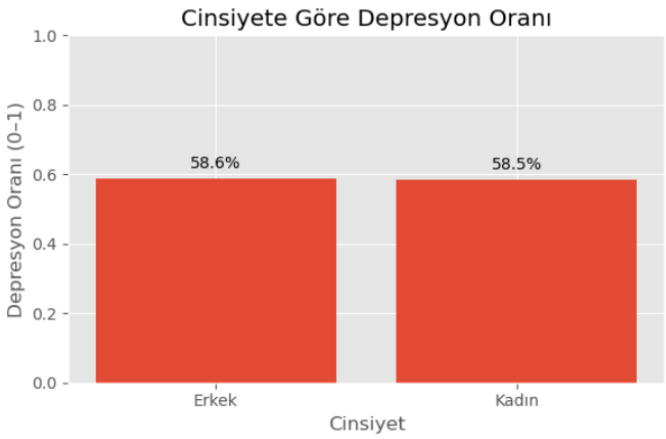

Şekil 3: Cinsiyete Göre Depresyon Oranı (EDA)

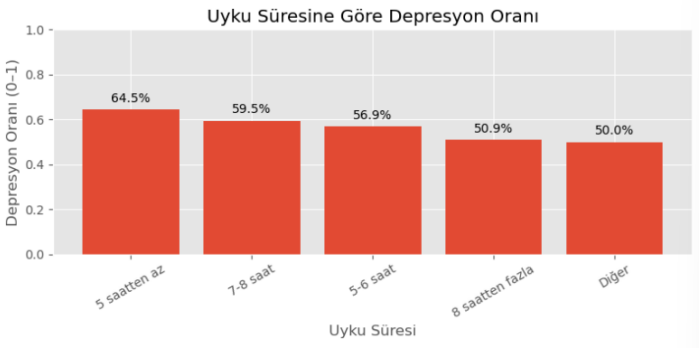

Şekil 4: Uyku Süresine Göre Depresyon Oranı (EDA)

Şekil 5 : Beslenme Alışkanlıklarına Göre Depresyon Oranı (EDA)

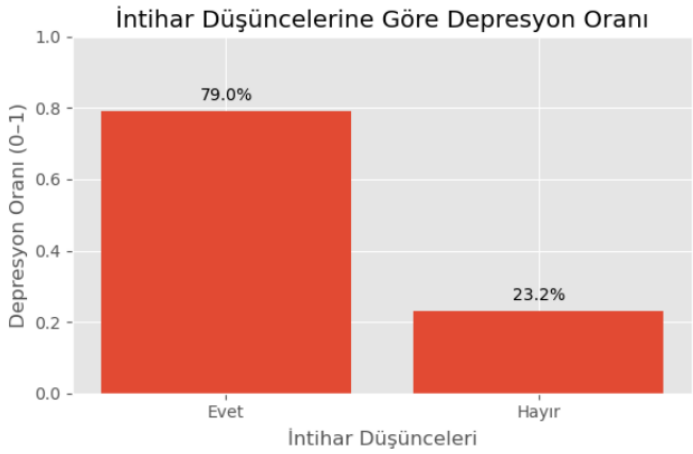

Şekil 6: İntihar Düşüncelerine Göre Depresyon Oranı (EDA)

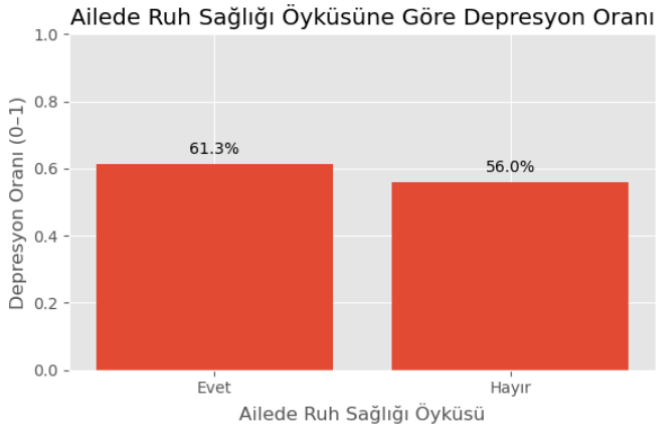

Şekil 7 : Ailede Ruh Sağlığı Öyküsüne Göre Depresyon Oranı (EDA)

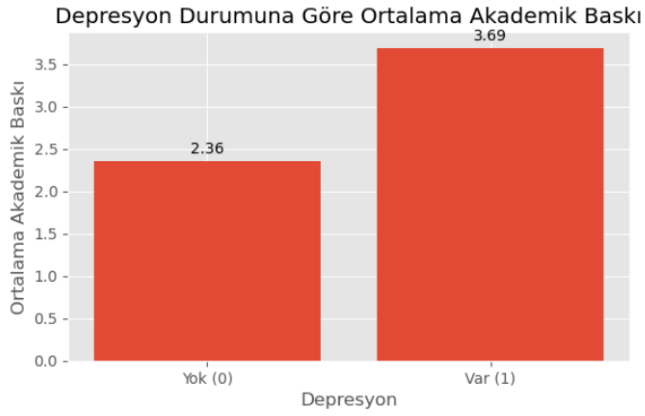

Şekil 8: Depresyon Durumuna Göre Akademik Baskı (EDA)

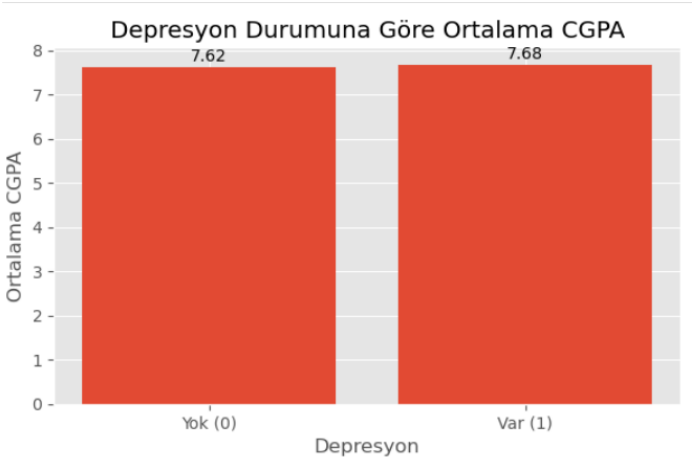

Şekil 9: Depresyon Durumuna Göre Ortalama (EDA)

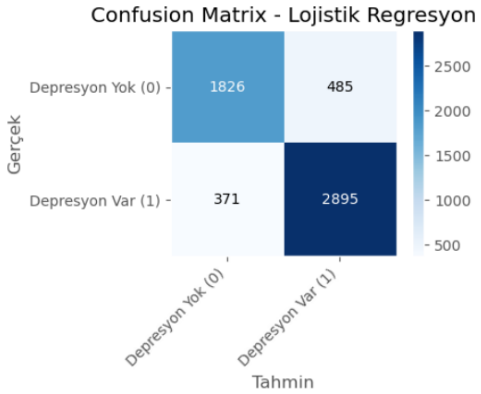

Şekil 10: Confusion Matrix (Lojistik Regresyon)

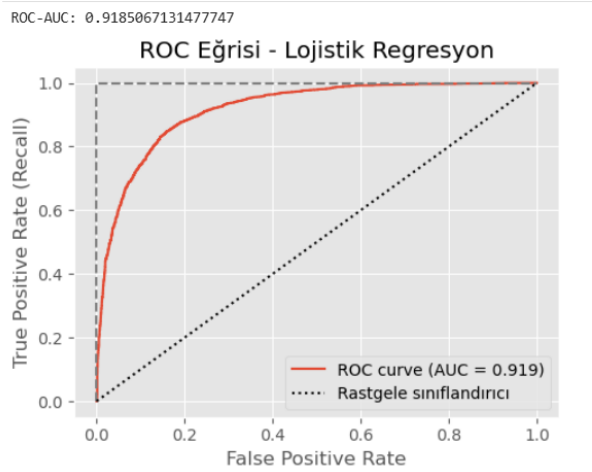

Şekil 11: ROC-AUC (Lojistik Regresyon)

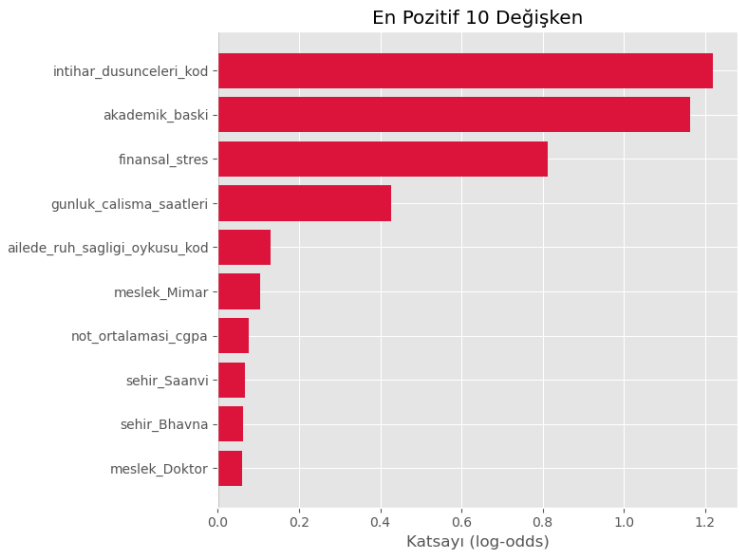

Şekil 12: Depresyona En Çok Etki Eden Değişkenler

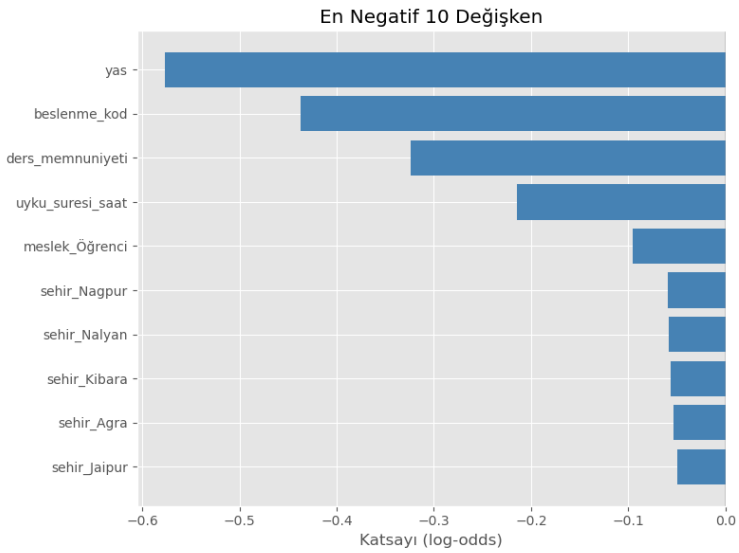

Şekil 13: Depresyona En Az Etki Eden Değişkenler

Ek–C: Orijinal Veri Seti

Şekil 14: Orijinal Veri Seti